

Feature Quality Analysis

Muhammad Fachrie

Tujuan Pembelajaran

- Menjelaskan konsep **feature relevance**, **redundancy**, dan **noise**.
- Melakukan **analisis korelasi antar fitur** menggunakan teknik statistik.

Konsep Dasar Feature Quality

a. Feature Relevance

- Feature dikatakan **relevan** jika:
 - Memiliki hubungan signifikan dengan **target variable (y)**.
 - Kontribusinya meningkatkan kemampuan model untuk memprediksi.
- Contoh:

Dalam prediksi harga rumah, luas bangunan dan jumlah kamar sangat relevan terhadap harga, sedangkan warna cat dinding mungkin tidak relevan.

Konsep Dasar Feature Quality

b. Feature Redundancy

- Feature **redundan** adalah fitur yang membawa **informasi yang sama atau sangat mirip** dengan fitur lain.
- Contoh:
“Total rooms” dan “bedrooms + living rooms” adalah fitur yang saling redundan karena satu bisa dijelaskan oleh kombinasi yang lain.
- **Masalah akibat redundancy:**
 - Model menjadi lebih kompleks tanpa menambah informasi.
 - Memperburuk generalisasi model.

Konsep Dasar Feature Quality

c. Feature Noise

- Feature **noise** adalah fitur yang tidak memiliki hubungan bermakna dengan target dan hanya menambah variabilitas acak.
- Contoh:
Nomor urut pelanggan, ID transaksi, timestamp yang tidak berulang, dll.
- **Dampak noise:**
 - Mengurangi performa model.
 - Meningkatkan risiko overfitting.
 - Menurunkan interpretabilitas.

Analisis Korelasi Antar Fitur

- Untuk mengukur kualitas dari masing-masing fitur/ atribut, umumnya dilakukan pengukuran korelasi:
 - Mutual information → feature relevance
 - Pearson correlation → feature redundancy
 - Chi-Square
 - Spearman

Mutual Information

Mutual Information (MI) memberikan informasi tentang seberapa banyak pengetahuan tentang X membantu kita memprediksi Y

$$I(X, Y) = \sum_{x,y} p(x, y) \cdot \log_2 \frac{p(x, y)}{p(x) \cdot p(y)}$$

di mana:

x, y : nilai di dalam X dan Y

$p(x, y)$: probabilitas gabungan dari X dan Y

$p(x)$: probabilitas kejadian x

$p(y)$: probabilitas kejadian y

Mutual Information

X1	X2	X3	Y (label)
1.2	A	X	0
2.5	A	X	0
3.0	B	Y	1
4.5	B	Y	1
5.1	B	Z	1
1.8	B	X	0
2.0	A	Z	0
4.8	B	Y	1
3.5	B	Z	1
0.9	B	X	0

Untuk menghitung mutual information (MI) dari dataset di samping, kita harus mengubah kolom X1 menjadi kategorik terlebih dahulu. Hal ini karena MI hanya dapat digunakan pada data bertipe nominal (kategorikal).

Misal, ambil rata-rata dari X1, yakni $2.93 \approx 3.00$. Lalu kita buat dua kategori berikut:

- X1 bernilai **high** jika $X1 > 3.00$
- X1 bernilai **low** jika $X1 \leq 3.00$

Mutual Information

X1	X2	X3	Y (label)
low	A	X	0
low	A	X	0
low	B	Y	1
high	B	Y	1
high	B	Z	1
low	B	X	0
low	A	Z	0
high	B	Y	1
high	B	Z	1
low	B	X	0

Lalu hitung MI untuk tiap feature dengan Y:

X1 dan Y:

- $p(\text{low}) = 6/10$; $p(\text{high}) = 4/10 \rightarrow p(x)$
- $p(\text{low}, 1) = 1/10$; $p(\text{low}, 0) = 5/10 \rightarrow p(x,y)$
- $p(\text{high}, 1) = 4/10$; $p(\text{high}, 0) = 0/10 \rightarrow p(x,y)$
- $p(1) = 5/10$; $p(0) = 5/10 \rightarrow p(y)$

maka, MI untuk X1 dan Y dihitung:

$$\begin{aligned}
 MI_{(X1,Y)} &= p(\text{low}, 1) \log_2 \frac{p(\text{low}, 1)}{p(\text{low}) \cdot p(1)} + p(\text{low}, 0) \log_2 \frac{p(\text{low}, 0)}{p(\text{low}) \cdot p(0)} \\
 &+ p(\text{high}, 1) \log_2 \frac{p(\text{high}, 1)}{p(\text{high}) \cdot p(1)} + p(\text{high}, 0) \log_2 \frac{p(\text{high}, 0)}{p(\text{high}) \cdot p(0)}
 \end{aligned}$$

Mutual Information

X1	X2	X3	Y (label)
low	A	X	0
low	A	X	0
low	B	Y	1
high	B	Y	1
high	B	Z	1
low	B	X	0
low	A	Z	0
high	B	Y	1
high	B	Z	1
low	B	X	0

Lalu hitung MI untuk tiap feature dengan Y:
X2 dan Y:

- $p(A) = 3/10$; $p(B) = 7/10$
- $p(A, 1) = 0/10$; $p(A, 0) = 3/10$
- $p(B, 1) = 5/10$; $p(B, 0) = 2/10$
- $p(1) = 5/10$; $p(0) = 5/10$

maka, MI untuk X2 dan Y dihitung:

$$\begin{aligned} MI_{(X2,Y)} &= p(A, 1) \log_2 \frac{p(A, 1)}{p(A) \cdot p(1)} + p(A, 0) \log_2 \frac{p(A, 0)}{p(A) \cdot p(0)} \\ &+ p(B, 1) \log_2 \frac{p(B, 1)}{p(B) \cdot p(1)} + p(B, 0) \log_2 \frac{p(B, 0)}{p(B) \cdot p(0)} \end{aligned}$$

Mutual Information

X1	X2	X3	Y (label)
low	A	X	0
low	A	X	0
low	B	Y	1
high	B	Y	1
high	B	Z	1
low	B	X	0
low	A	Z	0
high	B	Y	1
high	B	Z	1
low	B	X	0

Lalu hitung MI untuk tiap feature dengan Y:
X3 dan Y:

- $p(X) = 4/10$; $p(Y) = 3/10$; $p(Z) = 3/10$
- $p(X, 1) = 0/10$; $p(X, 0) = 4/10$
- $p(Y, 1) = 3/10$; $p(Y, 0) = 0/10$
- $p(Z, 1) = 2/10$; $p(Z, 0) = 1/10$
- $p(1) = 5/10$; $p(0) = 5/10$

maka, MI untuk X3 dan Y dihitung:

$$\begin{aligned}
 MI_{(X3,Y)} &= p(X, 1) \log_2 \frac{p(X, 1)}{p(X) \cdot p(1)} + p(X, 0) \log_2 \frac{p(X, 0)}{p(X) \cdot p(0)} \\
 &+ p(Y, 1) \log_2 \frac{p(Y, 1)}{p(Y) \cdot p(1)} + p(Y, 0) \log_2 \frac{p(Y, 0)}{p(Y) \cdot p(0)} \\
 &+ p(Z, 1) \log_2 \frac{p(Z, 1)}{p(Z) \cdot p(1)} + p(Z, 0) \log_2 \frac{p(Z, 0)}{p(Z) \cdot p(0)}
 \end{aligned}$$

Korelasi Pearson

- Digunakan untuk fitur numerik yang bersifat kontinu.

$$r = \frac{Cov(X, Y)}{\sigma_X \sigma_Y}$$

di mana:

$Cov(X, Y)$: kovarian antara atribut X dan Y

σ : standar deviasi

Korelasi Pearson

- $$Cov(X, Y) = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})$$

- $$\sigma_X = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X - \bar{X})^2}$$

di mana:

n : jumlah data

$\bar{X}$: nilai rata-rata (mean) dari X

Korelasi Pearson

- Interpretasi nilai kovarian:

Jenis hubungan	Pola	Covariance
Naik bersama (positif)	↗↗	(> 0)
Satu naik, satu turun	↗↘	(< 0)
Tidak berhubungan	acak	≈ 0

- Interpretasi nilai pearson:

semakin dekat r ke 1 atau -1, semakin “mirip” informasi antar fitur (redundan). Pada umumnya, jika ada pasangan fitur dengan $|r| > 0.9 \rightarrow$ salah satu bisa dihapus.

Contoh Pearson Correlation

- Misalkan terdapat dataset sbb:

ID	X1	X2	X3
1	1.0	2.176405	0.772852
2	2.0	4.040016	2.945128
3	3.0	6.097874	2.713245
4	4.0	8.224089	2.546010
5	5.0	10.186756	3.532636
6	6.0	11.902272	4.000409
7	7.0	14.095009	5.992895
8	8.0	15.984864	4.553810
9	9.0	17.989678	5.775681
10	10.0	20.041060	4.975085

Contoh Pearson Correlation

