

Feature Scaling

Muhammad Fachrie

Pendahuluan

- **Feature scaling** adalah proses mengubah nilai suatu feature ke dalam skala baru.
- Misalnya, mengubah feature “harga” yang nilainya dalam rentang [100.000, 1.000.000] ke dalam skala yang lebih kecil dalam rentang [1, 10] (nilai asli dibagi 100.000).
- Dalam machine learning, feature scaling identic dengan mekanisme **data normalization**.

Urgensi

- Data normalization dibutuhkan ketika suatu dataset berisi sejumlah feature yang memiliki rentang nilai yang beragam

KaryawanID	Kinerja	Tanggung	Usia	Gaji	Layak_Promosi
K001	0.91	2	32	8500000	Ya
K002	0.42	0	24	4500000	Tidak
K003	0.91	2	34	15000000	Ya
K004	0.65	1	29	6500000	Tidak
K005	0.70	3	50	11000000	Tidak
K006	0.77	2	38	9000000	Ya
K007	0.50	0	22	4200000	Tidak
K008	0.95	4	55	15000000	Ya

Urgensi (2)

- Dataset dengan feature yang beragam rentang nilainya, akan menurunkan kemampuan *learning* pada sejumlah algoritma machine learning, misalnya Neural Networks, SVM, dan KNN.
- Neural Networks dan SVM hanya mampu mengolah data dalam rentang yang kecil, misalnya $[0, 1]$ atau $[-1, 1]$.
- KNN sangat sensitif terhadap nilai yang berbeda skala, karena nilai *distance* yang dihasilkan menjadi tidak akurat.

Urgensi (3)

KaryawanID	Kinerja	Tanggungan	Usia	Gaji	Layak_Promosi
K001	0.91	2	32	8500000	Ya
K002	0.42	0	24	4500000	Tidak
K003	0.91	2	34	15000000	Ya

Jarak data antara:

- K001 dan K002

$$d = |0.91 - 0.42| + |2 - 0| + |32 - 24| + |8,500,000 - 4,500,000| = 4,000,010$$

- K001 dan K003

$$d = |0.91 - 0.91| + |2 - 3| + |32 - 35| + |8,500,000 - 15,000,000| = 6,500,002$$

Urgensi (4)

- Jarak antara K001 dengan K002 jauh lebih kecil dibandingkan dengan jarak antara K001 dengan K003. Padahal, K001 memiliki kemiripan yang sangat dekat dengan K003 pada 3 dari 4 feature yang ada pada dataset.
- Hal ini yang dimaksud dengan pengukuran jarak yang tidak akurat karena rentang nilai tiap feature sangat beragam.

Data Normalization

- Setidaknya terdapat tiga metode utama yang sering digunakan untuk melakukan feature scaling atau data normalization:
 - a. Min-max scaling
 - b. Z-score scaling
 - c. Robust scaling

Metode	Tujuan Utama	Rentang Hasil Akhir
Min-Max Scaling	Membatasi rentang nilai	[0, 1] (Terbatas)
Z-Score	Pusat (Mean=0) & Sebaran (Std=1)	Tidak Terbatas
Robust Scaling	Pusat (Median=0) & Sebaran (IQR)	Tidak Terbatas

Min-max Scaling

Min-max scaling mengubah nilai feature ke dalam rentang [0,1]

$$X' = \frac{X - X_{min}}{X_{max} - X_{min}}$$

di mana,

X : nilai yang akan dinormalisasi

X_{max} : nilai terbesar di dalam feature

X_{min} : nilai terkecil di dalam feature

Min-max Scaling (2)

Kinerja	Tanggung	Usia	Gaji
0.91	2	32	8500000
0.42	0	24	4500000
0.91	2	34	15000000
0.65	1	29	6500000
0.70	3	50	11000000
0.77	2	38	9000000
0.50	0	22	4200000
0.95	4	55	15000000



Kinerja	Tanggung	Usia	Gaji
0.92	0.50	0.30	0.40
0.00	0.00	0.06	0.03
0.92	0.50	0.36	1.00
0.43	0.25	0.21	0.21
0.53	0.75	0.85	0.63
0.66	0.50	0.48	0.44
0.15	0.00	0.00	0.00
1.00	1.00	1.00	1.00

Z-score Scaling

Z-score scaling bertujuan untuk merekayasa data sedemikian rupa sehingga data tersebut memiliki mean=0 dan standar deviasi=1.

$$X' = \frac{X - \mu}{\sigma}, \text{ di mana } \sigma = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X - \bar{X})^2}$$

dan

X : data yang akan dinormalisasi

μ : rata-rata (mean) dari feature

σ : standar deviasi dari feature

Z-score Scaling (2)

Kinerja	Tanggung	Usia	Gaji
0.91	2	32	8500000
0.42	0	24	4500000
0.91	2	34	15000000
0.65	1	29	6500000
0.70	3	50	11000000
0.77	2	38	9000000
0.50	0	22	4200000
0.95	4	55	15000000



Kinerja	Tanggung	Usia	Gaji
1.00	0.19	-0.32	-0.18
-1.66	-1.35	-1.05	-1.19
1.00	0.19	-0.14	1.46
-0.41	-0.58	-0.59	-0.69
-0.14	0.96	1.32	0.45
0.24	0.19	0.23	-0.05
-1.23	-1.35	-1.23	-1.27
1.22	1.73	1.77	1.46

Robust Scaling

Robust scaling mengubah nilai feature menggunakan statistik yang "*robust*" (tahan) terhadap outliers.

$$X' = \frac{X - Q_2}{Q_3 - Q_1}$$

di mana,

X : data yang akan dinormalisasi

Q_1 : kuartil pertama dari feature

Q_2 : median atau kuartil kedua dari feature

Q_3 : kuartil ketiga dari feature

Robust Scaling (2)

Kinerja	Tanggung	Usia	Gaji
0.91	2	32	8500000
0.42	0	24	4500000
0.91	2	34	15000000
0.65	1	29	6500000
0.70	3	50	11000000
0.77	2	38	9000000
0.50	0	22	4200000
0.95	4	55	15000000



Kinerja	Tanggung	Usia	Gaji
0.47	0.00	-0.05	-0.03
-0.85	-0.80	-0.41	-0.47
0.47	0.00	0.05	0.69
-0.23	-0.40	-0.18	-0.25
-0.09	0.40	0.78	0.25
0.09	0.00	0.23	0.03
-0.63	-0.80	-0.51	-0.51
0.58	0.80	1.01	0.69